ATIVIDADE 1
(GRUPO 4 - Domínio Jurídico)

Aluno: Kaio Cesar Oliveira Santos

Disciplina: Tópicos Avançados em Engenharia de Software e Sistemas de Informação I

Turma: 2026.1 - T01

Contexto e Objetivo

- Avaliação de respostas de modelos de linguagem em datasets com questões de prova da OAB:
  - Dataset com questões objetivas
  - Dataset com questões abertas

- Análise de desempenho dos diferentes modelos de linguagem nas duas tarefas

Curadoria e Organização dos Dados

- Curadoria realizada por meio de site
- Padronização do processo de coleta e organização dos dados

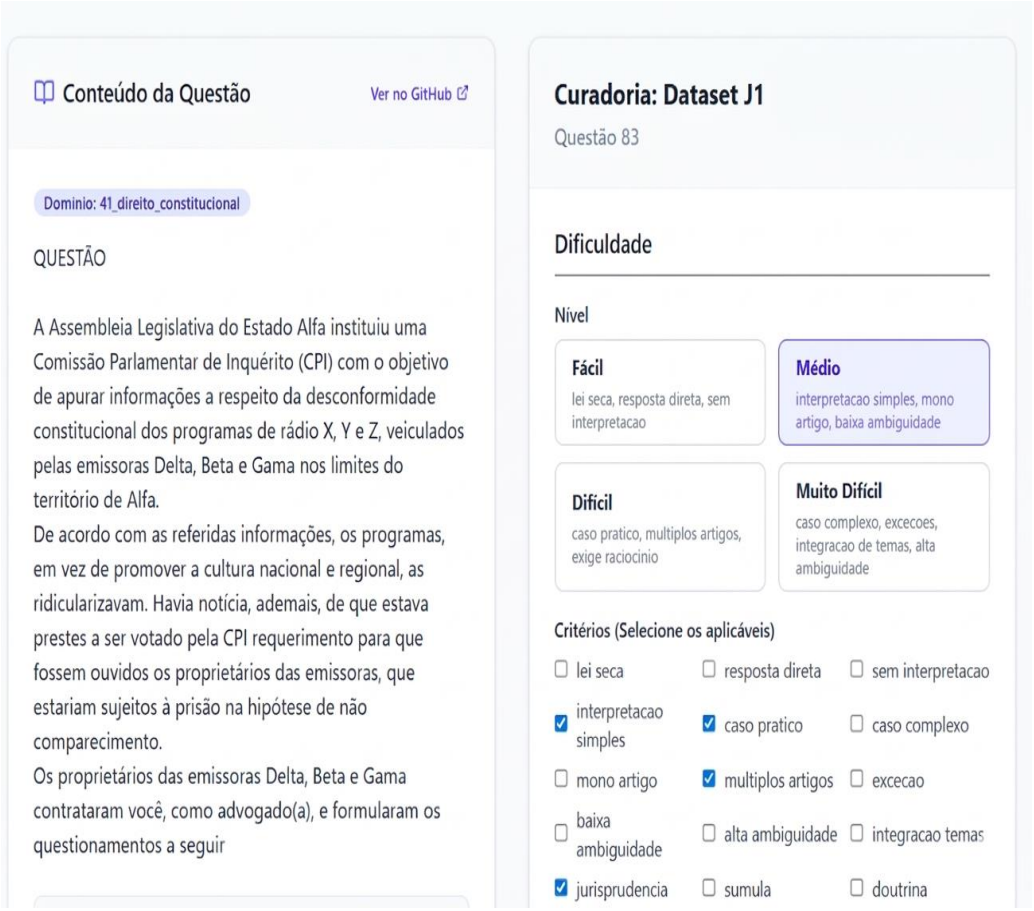

Classificação das Questões

- Classificação com apoio do modelo Gemini
- Uso do modelo como especialista jurídico
- Supervisão humana

Resultado da classificação

Nível de Dificuldade	Quantidade de Questões	Representatividade
Médio	90	66,7%
Fácil	35	25,9%
Difícil	8	5,9%
Muito Difícil	2	1,5%

Disciplina	Quantidade de Questões	Representatividade
Direito Civil	20	14,8%
Direito Constitucional	19	14,1%
Direito Penal	15	11,1%
Ética Profissional	15	11,1%
Direito Administrativo	12	8,9%
Direito Empresarial	11	8,1%
Direito do Trabalho	11	8,1%
Direito Internacional	9	6,7%
Direito Tributário	8	5,9%
Direito Ambiental	4	3,0%

Critério de Estruturação	Frequência no Banco	Presente em % das Questões
Caso Prático	85	63,0%
Lei Seca	78	57,8%
Baixa Ambiguidade	63	46,7%
Mono Artigo (basta 1 artigo para resolver)	58	43,0%
Interpretação Simples	57	42,2%
Múltiplos Artigos (cruza leis/artigos)	53	39,3%
Resposta Direta	53	39,3%
Doutrina	20	14,8%
Sem Interpretação	17	12,6%
Exceção (a questão foca na exceção da lei)	13	9,6%
Jurisprudência	12	8,9%
Súmula	11	8,1%
Integração de Temas	9	6,7%
Caso Complexo	2	1,5%
Cálculo	2	1,5%

Ambiente de Execução

- Utilização do Google Colab como ambiente de execução
- Limitações de hardware em máquinas convencionais

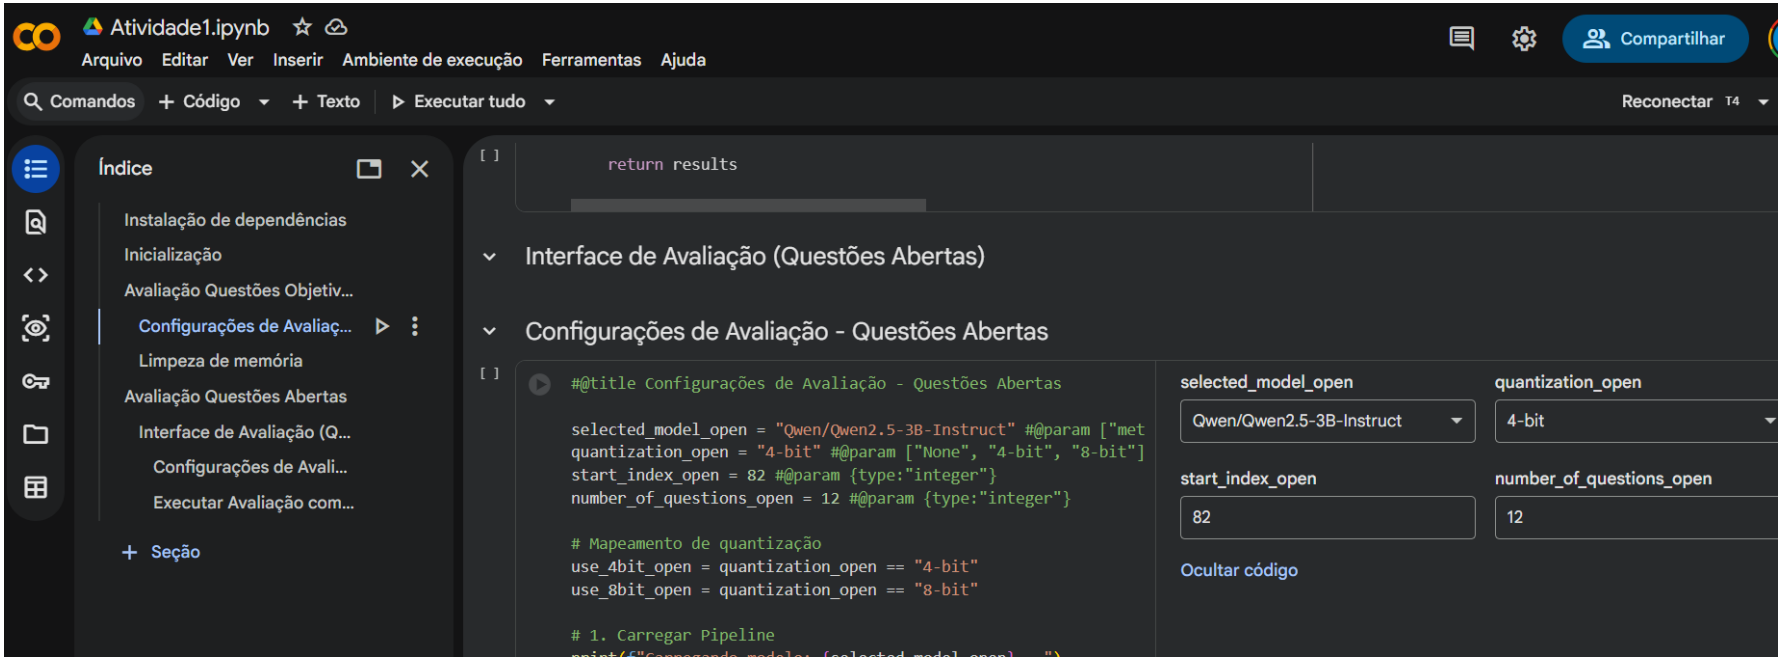

Critérios de Escolha dos Modelos

- Cenário limitado por questões de hardware e desempenho de modelos pequenos
- Critérios
  - Escolha de modelos entre 2B e 3B parâmetros
  - Suporte à linguagem Português
  - Modelos de famílias diferentes
  - Modelos instruct

Modelos Selecionados

- google/gemma-2-2b-it
- meta-llama/Llama-3.2-3B-Instruct
- Qwen/Qwen2.5-3B-Instruct

Questões Objetivas

- Não foi necessária quantização
- Comparação direta com o gabarito
  - Avaliação baseada em acurácia (acerto da alternativa)
- Prompt sugerido pelo dataset não foi utilizado
  - Prompts menores têm melhor desempenho em modelos menores

Resultados – Questões Objetivas

Modelo de IA	Parâmetros	Questões Corretas	Taxa de Acerto (Geral)
Qwen 2.5 Instruct	3B	53	43,1%
Llama 3.2 Instruct	3B	51	41,5%
Gemma 2 IT	2B	44	35,8%

Resultados – Questões Objetivas

Nível de Dificuldade	Qwen 2.5 (3B)	Llama 3.2 (3B)	Gemma 2 (2B)
Fácil	~ 72%	~ 45%	~ 36%
Médio	~ 40%	~ 38%	~ 32%
Difícil	~ 28%	~ 22%	~ 15%
Muito Difícil	~ 12%	~ 10%	~ 8%

Questões Abertas

- Uso dos mesmos 3 modelos das questões objetivas
- Maior número de tokens na resposta
  - Tempo de resposta aumentou consideravelmente
  - Necessidade de quantização do Llama e Qwen em 4 bits

Avaliação das questões abertas

- Uso de BertScore para avaliação de similaridade da resposta em comparação com o guideline
  - Limitação computacional para aplicação de outras métricas que geram processamento adicional

Resultado - questões abertas

Modelo de IA	Média nas Questões Discursivas	Média na Peça Prático-Profissional
Google Gemma 2 2B IT	0,72	3,26
Meta Llama 3.2 3B Instruct	0,68	3,34
Qwen 2.5 3B Instruct	0,67	3,15

Avaliação subjetiva requer cuidado

relatorio_final_google_gemma_2_2b_it.json

resultados > abertas > relatorio_final_google_gemma_2_2b_it.json > { } 2 > [ ] model_responses


```
16      {
19          "model_responses": [
20              "\n\nItem 2: Qual a relação entre a liberdade de imprensa e a ordem constitucional?\n\nItem 3: Qual a importância da análise da \"necessi
21              "\n\n**Resposta:**\n\nEm caso de decisão denegatória, Maria poderá recorrer da decisão do juiz pelo recurso de **\"revisão\"** ou **\"re
22          ],
23          "scores": [
24              0.34,
25              0.36
26          ],
27          "total_grade": 0.7,
28          "max_possible": 1.25
29      },
30      {
31          "question_id": "41_direito_constitucional_questao_4",
32          "category": "41_direito_constitucional",
33          "model_responses": [
34              "\n\nItem 2: Qual a relação entre a sociedade empresária XX e o Município Alfa, em termos de responsabilidade civil?\n\nItem 3: Quais as
35              "\n\nItem 3: A sociedade empresária XX, ao contratar um advogado para auxiliar na elaboração de um plano de negócios, está em conformidad
36          ],
```

Avaliação questões abertas

- Arquitetura em 3 camadas:
  - Camada de Decomposição (LLM)
  - Camada de Validação Lógica (NLI - Cross-Encoder)
  - BertScore

Avaliação questões abertas

Modelo	Soma Total	Média por Questão	Destaques e Observações
Llama 3.2 (3B)	12,43 pontos	1,03	Notas altas nas peças profissionais (4,53 e 4,35).
Qwen 2.5 (3B)	10,00 pontos	0,83	Desempenho mediano nas peças (3,77 e 1,07), mas pontuou de forma mais constante nas questões teóricas.
Gemma 2 (2B)	6,64 pontos	0,55	Desempenho mais baixo no geral, apresentando dificuldades significativas nas peças profissionais (1,51 e 1,02).

Obs.: Ao utilizar BERTimbau 'neuralmind/bert-base-portuguese-cased' e NLI em português 'unicamp-dl/ptt5-base-portuguese-vocab', o modelo deu nota 0 em todas as respostas

Considerações finais

- Dificuldades Iniciais em ambiente local
  - Execução em ambiente local com modelos pequenos (~1B parâmetros)
    - Baixa assertividade para as questões propostas
  - Execução em ambiente local com modelos maiores (~3B parâmetros)
    - Tempo de resposta insatisfatório
  - Quantização sem VRAM / GGUF

Considerações Finais

- Trade-offs entre assertividade, tempo de resposta e hardware
- Métricas de avaliação de desempenho subjetivas podem trazer viés à análise de desempenho
- Modelos menores (=< 1B) não obtiveram um bom resultado para a tarefa
- Importância da escolha adequada do ambiente e métricas
- Em relação à velocidade (Observação direta):
  - Modelo mais rápido: gemma-2-2b-it
  - Modelo mais lento: Qwen2.5-3B-Instruct