# Relatório

# de

# Kaio Cesar Oliveira Santos

**UNIVERSIDADE FEDERAL DE SERGIPE**

**Disciplina: Tópicos Avançados em E.S. e S.I. I**

**Docente: Dr. Glauco de Figueiredo Carneiro**

Equipe 4 - PROCC/UFS-2026.1

Discente: Kaio Cesar Oliveira Santos

**ATIVIDADE AVALIATIVA 1**: **Curadoria de Datasets e Inferência Básica com LLMs**

Vídeo

https://www.youtube.com/watch?v=qAP6T9f4UmA

Repositório público

https://github.com/kaioc89/Topicos_Avancados_2026-1_Equipe_JUD_4_atividade1_Kaio

## 1. Contribuições individuais

Participei das discussões para consolidar entendimento dos objetivos da tarefa e das definições de linhas de ação das atividades de grupo. Contribuí para sanar dúvidas do grupo quanto à utilização do dataset de questões abertas (J1) e objetivos individuais da atividade de inferência. Realizei a curadoria das questões designadas.

## 2. Contexto da atividade

Esta atividade engloba a curadoria de questões e avaliação de respostas de modelos de linguagem em datasets de domínio jurídico compostos por questões de provas objetivas e abertas da OAB. Esta abordagem permite avaliar os modelos sob os dois aspectos, lidando com tarefas jurídicas em diferentes níveis de complexidade.

## 3. Curadoria

A etapa de curadoria dos dados foi padronizada através da utilização de um site desenvolvido por um membro da equipe. O modelo Gemini foi empregado para a classificação das questões, atuando no papel de especialista jurídico sob supervisão. Esta etapa permitiu organizar as instâncias do dataset por disciplina, nível de dificuldade e critérios de estruturação (como presença de "Caso Prático", "Lei Seca", "Jurisprudência", entre outros).

Nesta tarefa, foram analisadas 123 questões objetivas e 12 questões abertas. Segue tabela contendo o número de questões classificadas por nível de dificuldade:

| **Nível de Dificuldade** | **Quantidade de Questões** | **Representatividade** |
|---|---|---|
| **Médio** | 90 | 66,7% |
| **Fácil** | 35 | 25,9% |
| **Difícil** | 8 | 5,9% |
| **Muito Difícil** | 2 | 1,5% |

## 4. Inferência

Esta etapa consiste na seleção dos modelos, avaliação das questões objetivas e avaliação das questões abertas.

### 4.1 Seleção dos modelos

Durante a etapa de seleção, foram testadas algumas possibilidades:

- Modelos de mesma família com tamanhos diferentes para verificar a influência do tamanho na assertividade do modelo
- Mesmo modelo com diferentes quantizações a fim de verificar a influência da quantização na assertividade do modelo

Ao tentar pôr em prática as configurações citadas, enfrentamos dificuldades relacionadas à restrições computacionais e também à lacunas de conhecimento sobre restrições de ambientes para execução de LLMs.

Além disso, notamos que modelos de tamanho menor ou igual a 1B apresentam uma assertividade muito baixa para a tarefa, chegando a não apresentar nenhuma resposta em alguns casos.

Devido às restrições apresentadas, selecionamos modelos entre 2B e 3B de parâmetros, os quais apresentaram resposta satisfatória para as tarefas. Como critérios de seleção adotamos modelos de famílias diferentes, que lidam bem com o português, e que são orientados a instruções (instruct). Considerando estes parâmetros, foram selecionados os seguintes modelos:

- google/gemma-2-2b-it
- meta-llama/Llama-3.2-3B-Instruct
- Qwen/Qwen2.5-3B-Instruct

## 4.2 Avaliação

Na etapa de avaliação, realizamos a obtenção dos datasets e submetemos as questões para os modelos de forma programática.

Devido às restrições computacionais de hardware em máquinas convencionais, o ambiente de desenvolvimento selecionado para esta tarefa foi o Google Colab, que permite a seleção de modelos de até 16GB de VRAM por tempo limitado em sua versão gratuita.

## 4.3 Questões objetivas

Para o subconjunto de questões objetivas, a inferência ocorreu de forma direta, sem a necessidade de quantização dos modelos. Considerando a mínima quantidade de tokens de resposta necessários para responder a uma pergunta de múltipla escolha e a análise objetiva da resposta, os modelos responderam em tempo satisfatório sem necessidade de quantização. A avaliação fundamentou-se na acurácia, realizando-se a comparação direta entre a alternativa gerada pelo modelo e o gabarito oficial da OAB.

No recorte das questões objetivas, o modelo Qwen 2.5 (3B) apresentou a melhor taxa de acerto geral, alcançando 43,1% (53 questões corretas). Ele foi seguido pelo Llama 3.2 (3B), com 41,5% de acertos (51 questões) , e pelo Gemma 2 (2B), com 35,8% (44 questões).

Em relação à assertividade comparada ao nível de dificuldade observa-se uma tendência dos modelos a serem menos assertivos quando o grau de dificuldade aumenta, o que valida a informação fornecida pela curadoria. Além disso, é importante destacar o desempenho do modelo Qwen 2.5 em questões fáceis, com um nível de assertividade muito acima dos demais.

| **Nível de Dificuldade** | **Qwen 2.5 (3B)** | **Llama 3.2 (3B)** | **Gemma 2 (2B)** |
|---|---|---|---|
| **Fácil** | ~ 72% | ~ 45% | ~ 36% |
| **Médio** | ~ 40% | ~ 38% | ~ 32% |
| **Difícil** | ~ 28% | ~ 22% | ~ 15% |
| **Muito Difícil** | ~ 12% | ~ 10% | ~ 8% |

Ainda em relação às características observadas nos modelos durante a execução da avaliação objetiva, foi possível notar, através de observação direta, que o modelo Qwen 2.5(3B) necessita de um tempo de resposta maior para apresentar uma resposta, enquanto o Gemma 2 se destacou com um tempo de resposta mais baixo que os demais.

4.4 Questões abertas

Devido ao aumento considerável no número de tokens gerados para respostas subjetivas e da complexidade da tarefa, o tempo de resposta dos modelos para essa tarefa aumentou consideravelmente. Considerando este cenário, foi necessário utilizar versão quantizada em 4 bits para os modelos Llama e Qwen.

Para avaliação das questões, utilizou-se uma arquitetura em 3 camadas:

- Camada de Decomposição (LLM) – o gabarito é submetido ao LLM que o decompõe em rúbricas (pequenas afirmações a serem checadas)

- Camada de Validação Lógica (NLI - Cross-Encoder) – Verifica, para cada rubrica criada na camada anterior, se a resposta atende à rubrica, somando pontos em caso afirmativo e removendo pontos se não atende. Se houver afirmação contrária, a penalidade é maior.
- Camada BertScore (ZHANG *et al.*, 2019) ajuda a medir se o tom e o vocabulário técnico estão alinhados ao esperado, realiza uma comparação semântica.

As questões foram submetidas aos modelos e a pontuação foi balanceada conforme pontuação da OAB, onde cada questão vale no máximo 1,25 e peças processuais valem 5 pontos. As questões foram submetidas de duas formas:

1 – Bertscore configurado para "pt" e NLI "cross-encoder/nli-deberta-v3-base". A avaliação apresentou o seguinte resultado após análise das 12 questões abertas:

| **Modelo** | **Soma Total** | **Média por Questão** | **Destaques e Observações** |
|---|---|---|---|
| **Llama 3.2 (3B)** | 12,43 pontos | **1,03** | Notas altas nas peças profissionais (4,53 em Direito Empresarial e 4,35 em Direito Penal). |
| **Qwen 2.5 (3B)** | 10,00 pontos | **0,83** | Desempenho mediano nas peças (3,77 e 1,07), mas pontuou de forma mais constante nas questões teóricas. |
| **Gemma 2 (2B)** | 6,64 pontos | **0,55** | Desempenho mais baixo no geral, apresentando dificuldades significativas nas peças profissionais (1,51 e 1,02). |

2 – Execução utilizando modelo Bert “BERTimbau” e NLI “unicamp-dl/ptt5-base-portuguese-vocab”. Todas as questões apresentaram nota zero para todos os modelos.

## 5. Conclusão

A etapa de curadoria, apoiada pelo modelo Gemini como especialista jurídico, demonstrou ser fundamental para a interpretação dos resultados. Observou-se uma correlação direta entre o nível de dificuldade atribuído na curadoria e a acurácia dos modelos nas questões objetivas.

A análise dos resultados obtidos na avaliação dos modelos Qwen 2.5 (3B), Llama 3.2 (3B) e Gemma 2 (2B) frente ao exame da OAB revela dados importantes sobre a capacidade de modelos de linguagem de pequeno porte no domínio jurídico. Os resultados indicam que a complexidade jurídica ainda representa um desafio significativo para modelos abaixo de 5 bilhões de parâmetros, revelando a necessidade de trabalhar com técnicas complementares, como fine tunning e RAG, para obtenção de melhores resultados.

Em relação às questões abertas, observou-se um desafio que transcende o *benchmark* dos modelos. Em questões subjetivas, a implementação de um *pipeline* de avaliação correto é tão importante quanto a qualidade da resposta dos modelos. Caso o *pipeline* não extraia uma avaliação correta, há o risco de um viés determinar que um modelo com respostas inferiores obtenha um aproveitamento superior. Inicialmente, utilizamos apenas o BertScore como métrica e pudemos perceber que respostas incorretas recebiam boas pontuações apenas por estarem alinhadas ao assunto da pergunta, sem de fato respondê-las. Após aplicar o modelo em 3 camadas, observamos que os resultados tiveram forte variação a partir dos dados de treinamento utilizados. Portanto, observa-se que a avaliação com métricas subjetivas requer rigor cauteloso para mitigar vieses na análise de desempenho.

Referências

PIRES, Ramon; MALAQUIAS JUNIOR, Roseval; NOGUEIRA, Rodrigo. Automatic Legal Writing Evaluation of LLMs. In: **Proceedings of the Twentieth International Conference on Artificial Intelligence and Law (ICAIL '25)**. New York: Association for Computing Machinery, 2026. p. 420–424. Disponível em: https://doi.org/10.1145/3769126.3769227.

ZHANG, Tianyi *et al*. **BERTScore: Evaluating Text Generation with BERT**. arXiv preprint arXiv:1904.09675, 2019. Disponível em: https://doi.org/10.48550/arXiv.1904.09675.